Guía de la Prueba de desempeño – Ruta de IA y Automatización

Orquestación de datos con Airflow y plataforma de consumo en tiempo real

Nombre de la prueba: Pipeline de datos automatizado con Apache Airflow, calidad, seguridad e IA, y plataforma de consumo en tiempo real (caso SismoWatch)

Ruta de formación a la que corresponde: IA y Automatización

Módulo: Orquestación y plataformas de datos (completar con el número de módulo asignado por Riwi)

Duración de la prueba: 8 horas, individual. La prueba tendrá un calendario semanal con la siguiente estructura para la jornada AM:

Hora	Día 1	Día 2	Día 3	Día 4	Día 5
06:00 – 08:00	Prueba técnica	Sustentación de la solución entregada (individual)*	Sustentación de la solución entregada (individual)*	Feedback personalizado por parte de tu TL*	Carga de resultados y feedback a Moodle por parte de tu TL*
08:00 – 08:20	Break 1	—	—	—	—
08:20 – 10:00	Prueba técnica	Trabajo individual	Trabajo individual	—	—
10:00 – 10:20	Break 2	—	—	—	—
10:20 – 12:00	Prueba técnica	Trabajo individual	Trabajo individual	—	—
12:00 – 12:20	Break 3	—	—	—	—
12:20 – 14:00	Prueba técnica	Trabajo individual	Trabajo individual	—	—

Notas: *Con previa cita asignada. Durante toda la jornada tendrás trabajo individual asignado en el cual deberás estar avanzando, mientras eres llamado a tu cita de sustentación o feedback en la sala de entrenamiento habitual. Durante el día 5 tu TL no estará disponible para resolver dudas, pero cuentas con tu tutor oficial.

Temas abordados

- Diseño de arquitecturas de datos por capas (raw, staging, curated) y definición del propósito de una arquitectura.
- Consumo de APIs públicas (REST/GeoJSON): paginación por ventanas, actualizaciones de registros y manejo de fallos.
- Orquestación de flujos con Apache Airflow: DAGs, tareas, dependencias, programación, reintentos, backfill e idempotencia.

- Contenedores con Docker y Docker Compose para levantar el ecosistema completo.
- Modelado y carga en PostgreSQL: schemas, upserts, roles y permisos.
- Calidad de datos: reglas de validación, cuarentena, frescura, volumen y métricas por ejecución.
- Seguridad en pipelines y plataformas: gestión de secretos, mínimo privilegio, autenticación JWT, control de acceso por roles y escaneo de vulnerabilidades.
- Automatización con IA: reportes generados con LLM, detección de anomalías, salidas estructuradas y controles contra información inventada.
- Desarrollo de una plataforma de consumo: API, dashboard, reportes, exportación y datos en tiempo real (WebSocket / SSE).
- Pruebas automatizadas con pytest (transformaciones, DAGs, reglas de calidad y endpoints).
- Documentación técnica y uso de Git.

Herramientas y recursos

- **Hardware requerido:** laptop o computadora con conexión a internet (otorgada por Riwi).
- **Software requerido:** Docker y Docker Compose, Python 3.11 o superior, Git, Node.js y npm (si el frontend lo requiere), navegador web (Chrome o Firefox), Visual Studio Code o cualquier IDE preferido.
- **Fuente de datos:** API pública USGS Earthquake Catalog (sin API key).
- **Recursos adicionales:** documentación oficial de Airflow, USGS, PostgreSQL, Docker, FastAPI, pytest, Great Expectations / Pandera, OWASP (incluido el Top 10 para aplicaciones con LLM) y del proveedor de IA elegido.

Objetivo de la prueba

Identificar tus capacidades para aplicar los conocimientos teóricos y hacer uso de tus habilidades prácticas en la construcción de una solución de datos automatizada de punta a punta: conectarte a una API pública, orquestar el procesamiento con Airflow, controlar la calidad y la seguridad de los datos, aplicar IA donde aporta valor y entregar una plataforma donde el usuario consuma sus datos en dashboard, reportes y tiempo real.

La prueba busca identificar el nivel de tus capacidades frente a:

- Definir con claridad el propósito de una arquitectura de datos y justificar sus decisiones.
- Construir pipelines automáticos, idempotentes y resilientes con Apache Airflow.
- Aplicar controles de calidad de datos y medidas de seguridad a lo largo del flujo.
- Automatizar tareas de análisis y reporte con IA de forma controlada y verificable.
- Desarrollar una plataforma de consumo con dashboard, reportes y datos en tiempo real.
- Aplicar buenas prácticas de desarrollo, pruebas, documentación y control de versiones.
- Defender técnicamente tu solución en una sustentación individual.

Estructura de la prueba

Esta prueba estará conformada principalmente por un caso de uso, en el cual encontrarás la **simulación de un escenario real**: un problema de negocio que requerirá aplicar múltiples conocimientos y evaluar tu capacidad de análisis, síntesis y uso de las herramientas adquiridas durante la ruta. Su estructura será la siguiente:

- **Parte 1 – Análisis y arquitectura:** entendimiento del negocio y de la fuente de datos, definición del propósito de la arquitectura, diagrama, capas y modelo de datos.
- **Parte 2 – Ingesta y orquestación:** conexión a la API, DAGs en Airflow, cargas idempotentes, reintentos, alertas y backfill.
- **Parte 3 – Calidad de datos y seguridad:** reglas de validación, cuarentena, métricas de calidad, gestión de secretos, roles de base de datos y escaneo.
- **Parte 4 – Automatización con IA:** reporte narrativo, detección de anomalías, controles contra información inventada y registro de ejecuciones.
- **Parte 5 – Plataforma de consumo y pruebas:** dashboard, reportes, tiempo real, control de acceso por rol y pruebas automatizadas.

Formato de las preguntas

El formato determinado para esta prueba será **caso de uso**. La prueba bajo este formato mide las habilidades de diseño, programación y resolución de problemas.

Permisos y limitaciones

Ten presente estas recomendaciones:

Lo que SÍ se puede hacer

- Uso de internet para consultar documentación oficial (Airflow, USGS, Docker, FastAPI, etc.).
- Utilizar recursos y ejemplos propios creados durante el entrenamiento.
- Usar asistentes de IA y copilotos de programación **como apoyo**, siempre que revises, entiendas y puedas explicar todo lo que entregas.

Lo que NO se puede hacer

- Compartir el caso con terceros.
- Comunicarte con otros coders o copiar código de terceros.
- Delegar la prueba completa en un agente o herramienta automática que entregue la solución sin que tú la comprendas ni la dirijas.
- Entregar código, configuraciones o decisiones de arquitectura que no puedas justificar en la sustentación.
- Subir credenciales, API keys o archivos `.env` reales al repositorio.

Implicaciones

- Esta prueba determina tu continuidad en el programa de entrenamiento, basado en el **Capítulo IV – Evaluación y calificación** del Reglamento interno de convivencia Riwi.
- Esta prueba tiene como objetivo identificar y evaluar el progreso del coder y su capacidad para resolver problemas prácticos.
- Se calificará tanto la solución técnica como la calidad de la sustentación.

Evaluación

- **Rúbrica de evaluación:** en la plataforma Moodle podrás consultar los criterios de evaluación asociados a esta prueba; te sugerimos revisarlos detenidamente para que enfoques tus esfuerzos en lo importante. Se evaluarán aspectos como arquitectura y propósito, ingesta y orquestación en Airflow, calidad de datos, seguridad, automatización con IA, plataforma de consumo, documentación, uso de Git y sustentación.
- **Ejecución de la entrega:** mediante la plataforma oficial Moodle en el respectivo espacio de entrega asignado por Riwi.
- **Visualización de los resultados:** en la plataforma oficial Moodle, al final del quinto día de la semana de evaluación.
- **Lugar de la retroalimentación:** en la sala habitual de entrenamiento durante el cuarto día de la semana de pruebas.

Preguntas guía para la sustentación

Prepárate para responder preguntas como las siguientes:

- ¿Cuál es el propósito de tu arquitectura, a quién sirve y qué decisiones permite tomar?
- ¿Por qué usaste Airflow y no un cron o un script? ¿Qué te aporta?
- ¿Cómo garantizas que ejecutar dos veces el mismo intervalo no duplica datos?
- ¿Qué ocurre en tu pipeline si la API de USGS no responde o devuelve datos incompletos?
- ¿Qué pasa con un registro que no pasa las reglas de calidad? ¿Dónde queda y cómo se ve?
- ¿Dónde están tus secretos y cómo evitas que lleguen al repositorio?
- ¿Qué permisos tiene cada rol de base de datos y por qué?
- ¿Cómo evitas que el modelo de IA invente cifras o siga instrucciones ocultas en los datos?
- ¿Cómo funciona el tiempo real en tu plataforma y qué pasa si se cae la conexión?
- ¿Cómo impides que un usuario “viewer” ejecute acciones de administrador, incluso llamando al endpoint directamente?
- ¿Qué cambiarías para llevar esta solución a producción?

¡Éxitos en este evento evaluativo!

Be a coder